



Derin Öğrenme Tabanlı Beyin Tümörü Sınıflandırma Ve Segmentasyon

Abdullah Sina KORKMAZ - Muhammet Emin KORKUNÇ

Nurettin SÜLEYMANOĞLU

Danışman: Dr. Öğr. Üyesi Abdulkerim Mohammed YIBRE



GİRİŞ


Bu proje, manyetik rezonans (MRI) beyin görüntüleri üzerinden beyin tümörlerinin otomatik olarak tespit edilmesini ve sınıflandırılmasını amaçlamaktadır. Manuel değerlendirme süreçlerinin zaman alıcı ve yoruma açık olması kısaca verim nedeniyle, derin öğrenme tabanlı yöntemler ile daha hızlı ve güvenilir bir karar destek sistemi geliştirilmesi hedeflenmiştir.

AMAÇ

Bu çalışmanın temel amacı, MRI beyin görüntülerini kullanarak:

- Tümör varlığını tespit etmek,
- Glioma, Meningioma, Pituitary ve No-Tumor** sınıflarını ayırt etmek,
- Tümör bölgesini **segmentasyon** ile belirlemek ve böylece klinik karar süreçlerine destek sağlamaktır.

Figure 6.1: NeuroScan AI System Architecture



METOT

Bu projede iki aşamalı bir yaklaşım benimsenmiştir:


1. Sınıflandırma:

MRI görüntüleri üzerinde özel olarak tasarlanmış bir Convolutional Neural Network (CNN) modeli eğitilmiştir. Model, dört sınıflı çıktı üretmektedir.


2. Segmentasyon:

Encoder-Decoder tabanlı bir mimari kullanılarak tümör bölgeleri piksel bazlı olarak ayrıştırılmıştır.


Eğitim sürecinde Adam optimizasyon algoritması ve uygun kayıp fonksiyonları kullanılmıştır.



Dört sınıflı beyin tümörü sınıflandırması için tasarlanan CNN mimarisi. Model, **ardışık evrim blokleri** ve **tam bağlantılı katmanlar** kullanılarak MRI görüntülerinden ayırt edici özellikler öğrenmektedir.



Dört sınıflı beyin tümörü sınıflandırmasına ait confusion matrix. Model, tüm sınıflar için yüksek doğruluk ve dengeli bir performans sergilemiş, sınıflar arası karışma oldukça **düşük seviyede** kalmıştır.



Örnek MRI görüntüsü üzerinde segmentasyon çıktısı:



- Model, tümör bölgesini piksel bazlı olarak ayırarak maskeyi üretmekte ve böylece **tümörün konumunu görsel** olarak göstermektedir.

Veri Seti


Projede açık erişimli MRI veri setleri kullanılmıştır:

- Çok sınıflı beyin MRI görüntüleri
- Gliom segmentasyon verileri (LGG)

Görüntüler eğitim, doğrulama ve test kümelerine ayrılmıştır.



Tümör bölgesinin piksel bazlı tespiti için kullanılan Encoder-Decoder (U-Net) segmentasyon mimarisi. Skip bağlantıları sayesinde uzamsal detaylar korunarak daha doğru maske çıktısı üretilmektedir.



Eğitim sürecinde doğruluk (**accuracy**) ve kayıp (**loss**) değerlerinin epoch'lara göre değişimi. Eğitim ve doğrulama eğrilerinin birbirine yakın seyretmesi, modelin kararlı şekilde öğrendiğini ve aşırı öğrenmenin (**overfitting**) sınırlı olduğunu göstermektedir.

ÖN İŞLEME

Projede kullanılan MRI görüntüleri, model girişine uygun hale getirilmeden önce çeşitli ön işleme adımlarından geçirilmiştir. Tüm görüntüler **sabit boyuta** getirilmiş, piksel değerleri **normalize** edilmiş ve modelin genelleme kabiliyetini artırmak amacıyla **veri artırma** teknikleri uygulanmıştır. Bu işlemler, modelin daha kararlı ve yüksek doğrulukla öğrenmesini sağlamıştır.

- Yeniden Boyutlandırma:** Tüm görüntüler 256x256 piksel olarak boyutlandırılmıştır.
- Veri Artırma** (Sadece Eğitim): Rastgele yatay çevirme ve rastgele döndürme ($\pm 10^\circ$).
- Normalizasyon:** ImageNet istatistikleri (ortalama=[0.485, 0.456, 0.406], ss=[0.229, 0.224, 0.225]).
- Tümör görünürlüğünü artırmak için **CLAHE** (Kontrast Sınırlı Uyarlamalı Histogram Eşitleme).

SONUÇ

Model test verisi üzerinde **yüksek doğruluk** elde etmiştir:

Class	Precision	Recall	F1 Score
Glioma	98.77%	99.15%	98.96%
Meningioma	98.73%	98.42%	98.58%
Pituitary	99.63%	100.00%	99.82%
No- Tumor	99.17%	98.84%	99.00%

Ayrıca sonuçlarda tüm sınıflar için **dengeli** ve **güvenilir** performans gözlemlenmiştir.

TARTIŞMA

- Segmentasyon modeli yalnızca glioma verisi ile eğitilmiştir; farklı tümör türlerini içeren **çok sınıflı segmentasyon** veri setleri ile model geliştirilebilir.
- Daha **büyük** ve **dengeli** veri setleri kullanılarak modelin genelleme kabiliyeti artırılabilir.
- 3B MRI** görüntülerin kullanılması, tümör hacminin daha doğru belirlenmesini sağlayabilir.
- Açıklanabilir yapay zekâ yöntemleri ile model çıktıları daha **yorumlanabilir hale** getirilebilir.
- Klinik ortamda gerçek zamanlı kullanım için modelin hesaplama maliyeti **optimize** edilebilir.